David Egbakou

Machine Learning Engineer | Data Scientist

Applied Machine Learning • Forecasting • ML Engineering

davidegbakou@gmail.com | +33 6 29 55 64 80 | Île-de-France, France

github.com/davekg8 | linkedin.com/in/david-egbakou

Profil

Élève ingénieur en informatique à CY Tech et **Data Scientist en alternance chez DHL Express**. Expérience en conception, évaluation et automatisation de systèmes de Machine Learning, notamment en **Deep Learning, forecasting global multi-séries et ensemble learning**. Responsable end-to-end d'un projet européen couvrant **39 pays et environ 800 agences**. Intérêt pour la modélisation ML, l'ingénierie des modèles et la recherche appliquée.
Disponibilité : CDI à partir de septembre/octobre 2027.

Expérience professionnelle

Data Scientist — Alternance *2025 – 2027*
DHL Express France | Performance & Opérations

- **Conception de modèles :** développement d'un système national de forecasting avec **DeepAR**, puis refonte autour de **XGBoost**, décomposition saisonnière **STL**, tendances dynamiques et corrections métier.
- **Évaluation expérimentale :** validation temporelle à 5 folds ; **WAPE de 3,8 %** pour le système V2 contre 5,5 % pour DeepAR V1, sur des périodes de validation partiellement chevauchantes.
- **ML Engineering :** automatisation des workflows d'entraînement, de réentraînement et d'inférence récursive à **12 semaines** sous **Dataiku DSS**. Gestion des modèles, Git, Target Encoding K-Fold et publication des prédictions dans **Snowflake**.
- **Data Engineering :** requêtes Snowflake et automatisations **PowerShell / RPA** pour alimenter un dashboard Power BI de suivi des transporteurs et retards routiers.

Data Scientist — Stage international — Leipzig, Allemagne *Été 2026*
DHL Express Europe

- **Responsabilité end-to-end :** conception en autonomie d'un système de prévision couvrant **39 pays et environ 800 agences**, avec prévisions aux niveaux agence et pays sur un horizon de **56 jours**.
- **Modélisation globale :** développement et comparaison de modèles multi-séries **DeepAR, Chronos-T5 et XGBoost**, exploitant les comportements partagés entre agences.
- **Ensemble learning :** combinaison de DeepAR et Chronos-T5 par **stacking avec gradient boosting**, complétée par des ajustements métier.
- **Robustesse des données :** conception d'un mécanisme de réattribution des historiques de colis pour tenir compte des changements de périmètre des agences.
- **Résultat : WAPE de 5,6 %** au niveau agence, sur un horizon de **56 jours**. Pipeline opérationnel sous **Dataiku DSS et Snowflake**.

Formation

Diplôme d'Ingénieur en Informatique (Data & IA) *2024 – 2027*
CY Tech | Cergy, France

Classes Préparatoires MPSI / MP *2022 – 2024*
Lycée Technique Errazi | El Jadida, Maroc

Projet technique

Architecture ML événementielle — Microservices *Octobre 2026*
Python | Apache Kafka, Docker, Flask, Scikit-learn

- **Architecture distribuée :** développement de microservices conteneurisés avec **Docker**, communiquant de manière asynchrone via **Apache Kafka** pour traiter des événements métier.
- **Intégration Machine Learning :** déploiement d'un service d'inférence **RandomForest**, avec séparation entraînement/inférence, traitement des messages Kafka et tests d'intégration du pipeline end-to-end.

GitHub — Code source du projet

Compétences techniques

Machine Learning	DeepAR, Chronos-T5, XGBoost, Scikit-learn, Prophet, ensemble learning, séries temporelles, STL
Méthodologie ML	Validation temporelle, cross-validation, feature engineering, stacking, évaluation de modèles
Programmation	Python, SQL, R, Java, Pandas, NumPy
ML & Data Engineering	Dataiku DSS, Snowflake, Git, pipelines ML, réentraînement, inférence, PostgreSQL
Outils complémentaires	Power BI, PowerShell, RPA
Langues	Français (courant), Anglais (B2, usage professionnel)